Cloud Security & Business Continuity: Implementazione Pratica di un Application Load Balancer

Progetto opzionale di approfondimento su infrastruttura Google Cloud

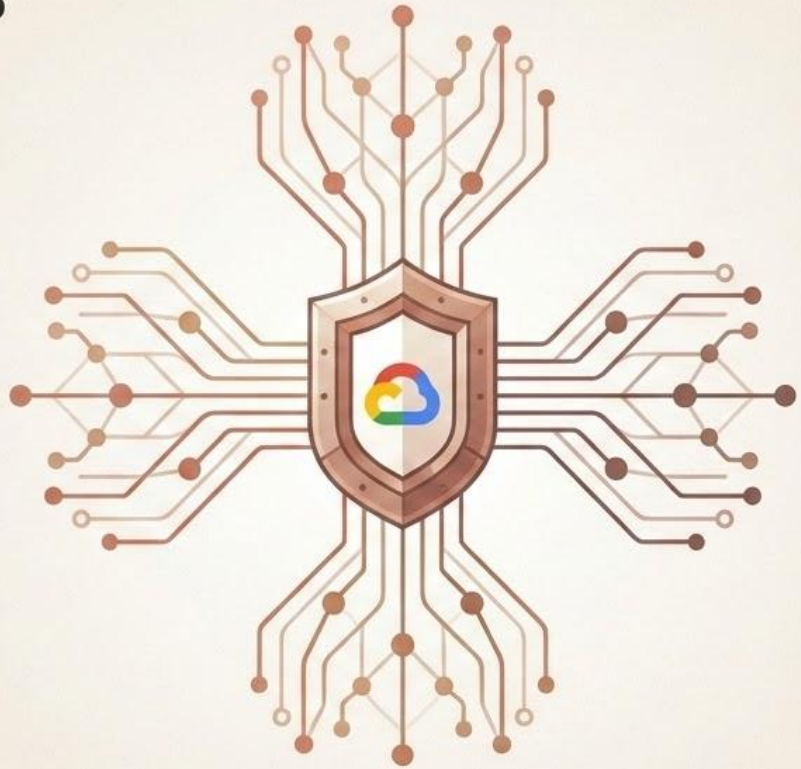

Presentato da: Lorenzo Delle Coste

Obiettivo: Dimostrare come il bilanciamento del carico non sia solo un fattore di performance, ma un pilastro fondamentale della sicurezza e della disponibilità del dato.

Perché ho scelto il Load Balancing?

Visione Personale

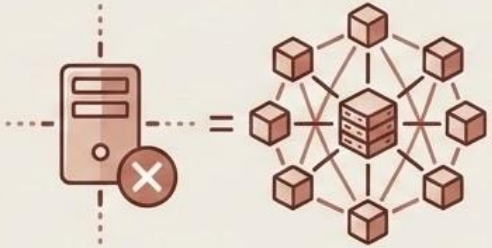

Analisi TCO

Focus Security

Visione Personale

Ho scelto di sviluppare questo caso pratico per esplorare come un'architettura distribuita possa prevenire il "Single Point of Failure" (punto di guasto singolo).

Analisi TCO

Rispetto a una soluzione server in ufficio, l'approccio Cloud riduce drasticamente il Total Cost of Ownership eliminando costi di hardware fisico ridondante, manutenzione e raffreddamento.

Focus Security

Il Load Balancer funge da scudo per i server backend, nascondendo i loro IP privati e filtrando il traffico in ingresso.

Cos’è il Load Balancing in ambiente Cloud?

Definizione Tecnica

Un servizio che distribuisce il traffico applicativo in arrivo su più risorse backend (VM, container) per garantire che nessun singolo server diventi un collo di bottiglia.

Architettura a Livello 7 (HTTP/S)

Analisi del funzionamento basato sul contenuto della richiesta (URL, header, cookie) per un instradamento intelligente.

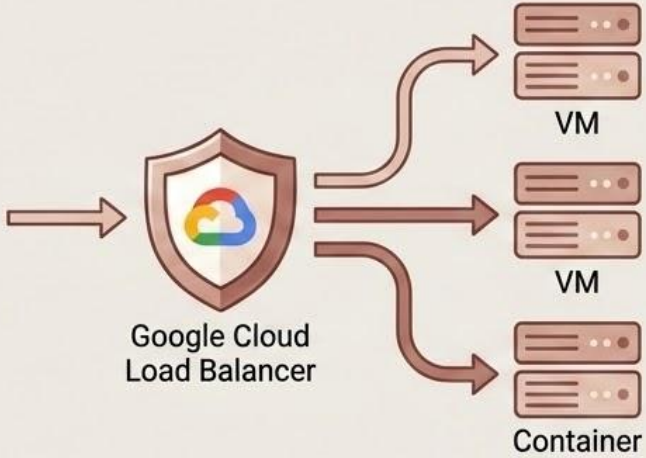

Obiettivi Primari

Scalabilità

Gestione di picchi di traffico improvvisi.

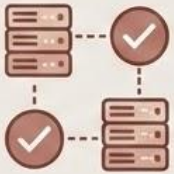

Disponibilità (High Availability)

Eliminazione del “Single Point of Failure”.

Sicurezza

Schermatura degli indirizzi IP reali dei server backend.

Meccanismi di Funzionamento e Algoritmi

Algoritmi di Distribuzione

Round Robin: Distribuzione sequenziale ed equa.

Least Connections: Instradamento verso il server con meno sessioni attive.

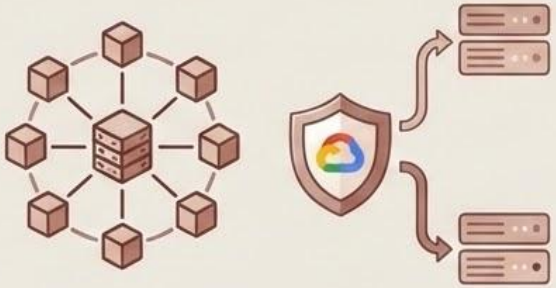

Health Checks (Controlli di Integrità)

Il cuore della resilienza. Il bilanciatore monitora costantemente la porta 80/443; se un server fallisce, viene isolato automaticamente per evitare disservizi.

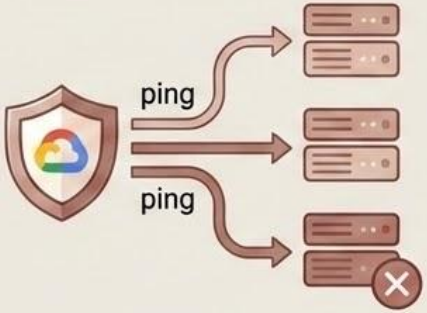

Session Affinity

Capacità di mantenere un utente collegato allo stesso server per la durata della sessione.

Analisi di Sicurezza: Load Balancer vs WAF

Protezione DDoS

Capacità nativa di assorbire attacchi volumetrici prima che raggiungano i server.

Integrazione WAF (Web Application Firewall)

Analisi di come il bilanciatore possa filtrare attacchi SQL Injection o Cross-Site Scripting (XSS).

SSL Offloading

Gestione della crittografia dei certificati sul bilanciatore per alleggerire il carico computazionale dei server backend.

Caso Pratico - Configurazione dell'Infrastruttura

Dal Punto di Vista Operativo: Ho voluto implementare personalmente questi concetti su Google Cloud Platform per validare la teoria.

Setup dei Nodi

Creazione di due VM Debian automatizzate via Startup Script, come mostrato

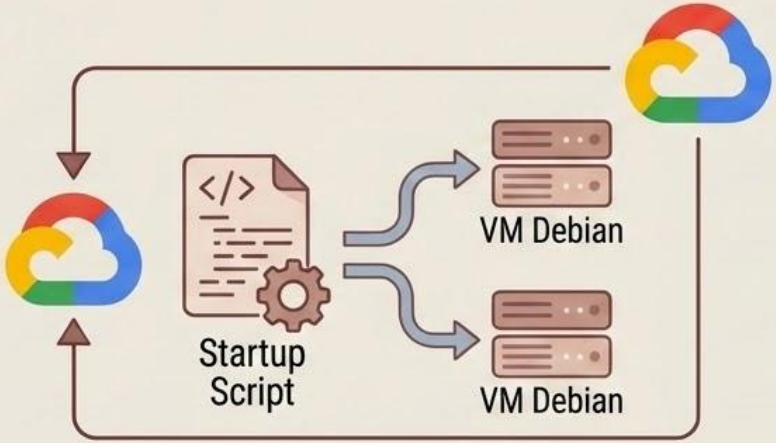

Mapping delle Risorse

Raggruppamento delle istanze in un Instance Group dedicato per il bilanciamento regionale

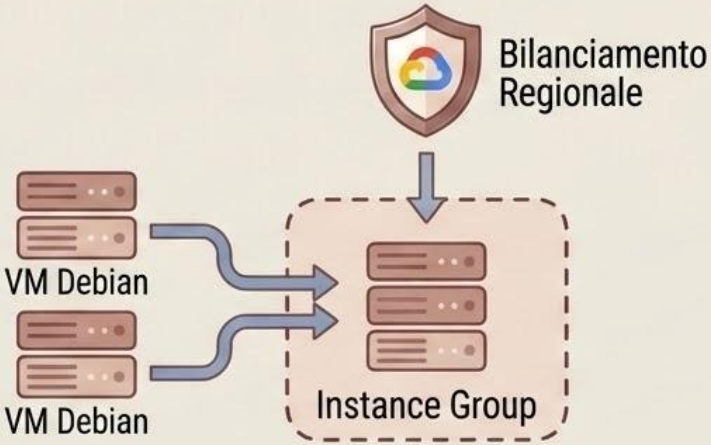

Google Cloud | Load balancer | Cerca (/) risorse, documenti, prodotti e altro | Cerca

Crea un'istanza | Crea VM da... | Codice equivalente

- Configurazione macchina
  e2-medium, europe-west1
- Sistema operativo e spazio di archiviazione
  Debian GNU/Linux 12 (bookworm)
- Protezione dei dati
  Pianificazioni snapshot
- Networking
  1 regola firewall, 1 interfaccia di rete
- Osservabilità
  Installa Ops Agent
- Sicurezza
- Avanzata

Configurazione macchina

Nome *
web-server-1

Regione *
europe-west1 (Belgio)
La regione è permanente

Zona *
Qualsiasi
Google sceglierà una zona per tuo conto, massimizzando l'ottenibilità della VM. La zona è permanente.

Genera suggerimenti sul tipo di macchina con Gemini Novità

Prompt
Genera

Descrivi il tuo workload e i tuoi requisiti (ad esempio costi o prestazioni). La generazione di suggerimenti sul tipo di macchina è gratuita.

Server web a basso costo | Database a basso volume | Inferenza AI/ML

✓ Uso generico | Ottimizzata per il calcolo | Ottimizzata per la memoria | Ottimizzato per l'archiviazione | GPU

Tipi di macchina per workload comuni, ottimizzati per costi e flessibilità

Series	Descrizione	vCPUs	Memory	Pia
C4	Prestazioni sempre elevate	2 - 288	4 - 2.232 GB	Int
C4A	Prestazioni elevate e uniformi basate su ARM	1 - 96	2 - 768 GB	Go

Stima mensile

27,91 USD
Circa 0,04 USD $ all'ora

Paga per quello che utilizzi: nessun costo iniziale e fatturazione al secondo

Elemento	Stima mensile
2 vCPU + 4 GB di memoria	26,91 USD
Disco permanente con carico bilanciato da 10 GB	1,00 USD
Logging	I costi sono variabili
Monitoraggio	I costi sono variabili
Pianificazione snapshot	I costi sono variabili
Total	27,91 USD

Prezzi di Compute Engine
Prezzi della Suite operativa di Google Cloud
Comprimi

Google Cloud | Load balancer | Cerca (/) risorse, documenti, prodotti e altro | Cerca

Crea un'istanza | Crea VM da... | Codice equivalente

- Configurazione macchina
  e2-medium, europe-west1
- Sistema operativo e spazio di archiviazione
  Debian GNU/Linux 12 (bookworm)
- Protezione dei dati
  Pianificazioni snapshot
- Networking
  1 regola firewall, 1 interfaccia di rete
- Osservabilità
  Installa Ops Agent
- Sicurezza
- Avanzata

Avanzata

Gestisci tag ed etichette

Descrizione

Protezione da eliminazione

☐ Attiva la protezione da eliminazione

Prenotazioni

- (●) Utilizza la selezione automatica
  Google Cloud selezionerà una prenotazione esistente che corrisponde alle proprietà della tua istanza
- ( ) Scegli una prenotazione
- ( ) Non utilizzare una prenotazione

Automazione

Script di avvio

```
apt-get update
apt-get install -y apache2
echo '<h1>Benvenuti dal Server 1</h1>' > /var/www/html/index.html
```

Puoi scegliere di specificare uno script di avvio che verrà eseguito quando la tua istanza si avvia o riavvia. Gli script di avvio possono essere utilizzati per installare software e aggiornamenti e per assicurare che i servizi siano in esecuzione nella macchina virtuale. Scopri di più

Stima mensile

27,91 USD
Circa 0,04 USD $ all'ora

Paga per quello che utilizzi: nessun costo iniziale e fatturazione al secondo

Elemento	Stima mensile
2 vCPU + 4 GB di memoria	26,91 USD
Disco permanente con carico bilanciato da 10 GB	1,00 USD
Logging	I costi sono variabili
Monitoraggio	I costi sono variabili
Pianificazione snapshot	I costi sono variabili
Total	27,91 USD

Prezzi di Compute Engine
Prezzi della Suite operativa di Google Cloud
Comprimi

Implementazione della Logica e del Firewall

Controllo di Resilienza

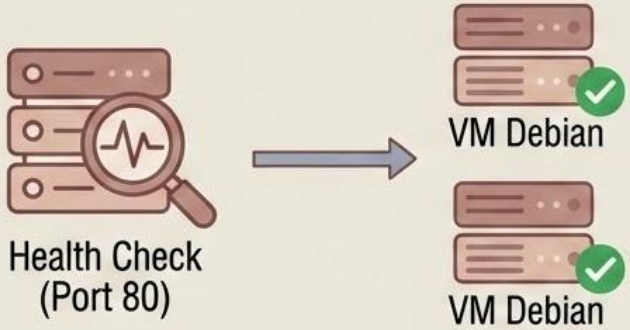

Configurazione dell'Health Check per monitorare la porta 80.

Networking Security

Apertura di regole firewall specifiche per permettere ai 'Probes' di Google di verificare lo stato dei server senza esporre la rete a rischi esterni.

Verifica Backend

Controllo dello stato 'Healthy' delle macchine nella console di gestione.

Bilanciamento del carico
Cloud DNS
Cloud CDN
Cloud NAT
Cloud Service Mesh (Traffic D...
Service Directory
Cloud Domains
Private Service Connect
Policy SSL
Service Extensions
Marketplace
Note di rilascio

Assicurati che tutti i campi siano corretti per continuare

Nome bilanciatore del carico *
ld1
Lettere minuscole, senza spazi

Regione
us-central1 (Iowa)

Rete *
default

Subnet solo proxy *
proxy-subnet-demo (192.168.0.0/23)

- Configurazione backend
- Regole di routing
- Configurazione frontend
- Esamina e finalizza (facoltativo)

Esamina e finalizza

Regione
us-central1

Frontend

Protocollo	Subnet	IP:Porta	Certificato	Policy SSL	Nome DNS
HTTP	default (10.128.0.0/20)	AUTOMATIC:80	-		

Regole host e percorso

Host	Percorsi	Backend
Tutti senza corrispondenza (valore predefinito)	Tutti senza corrispondenza (valore predefinito)	group-instance

Backend

Servizi di backend

1. group-instance

Protocollo endpoint	HTTP
Timeout	30 secondi
Policy di selezione degli indirizzi IP	Solo IPv4
Controllo di integrità	check-porta-80

Crea Annulla Codice equivalente

Crea servizio di backend

Protocollo
HTTP

Porta denominata *
http

Timeout *
30

Policy di selezione degli indirizzi IP
Solo IPv4

Controllo di integrità *
Filtra Digita per filtrare
Nessun risultato per ""
Crea un controllo di integrità

Nuovo backend

Tipo di stack IP
- IPv4 (stack singolo)
- IPv4 e IPv6 (stack doppio)

Gruppo di istanze *

Trasferisci numeri *

Crea Annulla

Controllo di integrità

Nome *
check-porta-80
Lettere minuscole, senza spazi

Descrizione

Regione
us-central1 (Iowa)

Protocollo
TCP

Porta *
80

Protocollo PROXY
Nessuna

Richiesta

Risposta

Log
- Attivata
  L'attivazione dei log per il controllo di integrità può comportare l'aumento dei costi in Logging.
- Off

Criteri integrità

Definiscono come viene determinato lo stato di integrità: frequenza di controllo, tempo di attesa di una risposta e numero di tentativi riusciti o non riusciti determinanti

Intervallo di controllo *
5 secondi

Timeout *
5 secondi

Crea Annulla

Demo Video - Stress Test e Failover

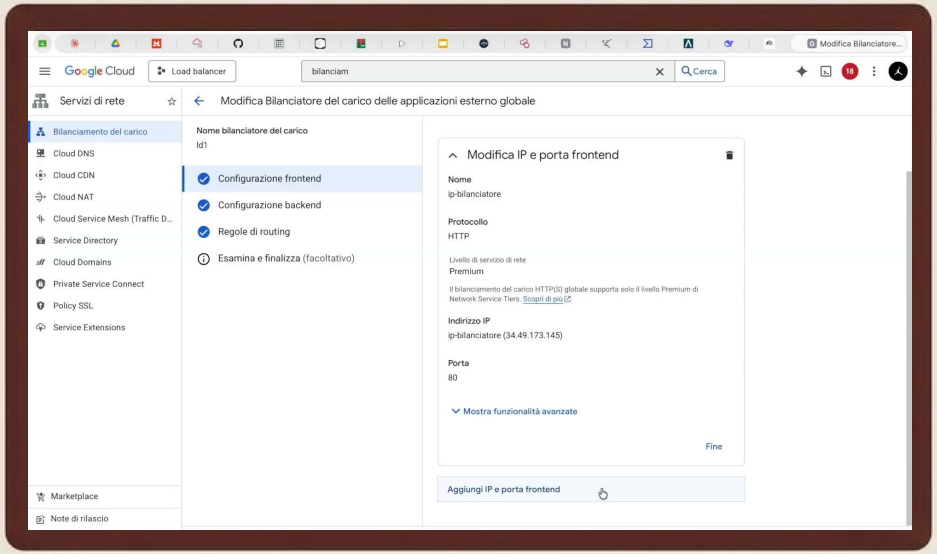

Cosa stiamo guardando:

Simulazione di un crash del server primario e reindirizzamento automatico del traffico.

Conclusione:

La prova pratica conferma che un'architettura Cloud bilanciata garantisce continuità del servizio anche in scenari di errore critico.